

MVP – Engenharia de dados PUC RIO

Nome: Rafael de Miras Escoriza

Matrícula: 4052026000297

Data: 27/09/2026

Curso: Ciência de dados e analytics

1 Objetivo

Estudar um banco de dados de alunos, e analisar quais possíveis características são mais importantes durante o período acadêmico para um maior salário inicial

1.1 Contexto

Como MVP de um trabalho acadêmico, foi levantado os questionamentos sobre quais são as características que mais influenciam no caminho final do aluno para receber um maior salário. Tais questões, visam entender e comparar diferentes tipos de questões sobre a vida acadêmica do aluno e o que mais o influencia, como esforço individual de estudo, certificações, participações em trabalhos extracurriculares, ou características de nascença.

1.2 Perguntas

A questão principal é:

- Quais fatores influenciam no salário inicial dos estudantes?

Dela será analisado os seguintes fatores:

- Horas de estudos
- Desempenho acadêmico
- Certificações

- Habilidade de comunicação e trabalho em equipe
- Proficiência em inglês
- Habilidades complementares/combinadas que se potencializam

1.3 Por quê

A pergunta principal serve como guia para orientar quais características têm maior probabilidade de influenciar o salário inicial dos alunos. Essas características foram agrupadas por tipo: esforço (horas de estudo), qualificação formal (certificações e cursos oficiais) e habilidades pessoais mais inatas (comunicação e liderança).

2 Busca e coleta de dados

Através da busca pelos sites disponibilizados, foi encontrada uma base sintética no site [Kaggle](#), com boa qualidade de informações dos estudantes durante seu período acadêmico e como isso influencia no seu salário inicial.

O link para download da base CSV se encontra abaixo:

[Student Career Success Prediction Dataset](#)

A base criada pela Mobeem Fatima consta a licença [CC BY-SA 4.0](#), na qual sou livre adaptar, compartilhar e mudar a base, contanto que dê créditos a criador, conforme já feito

Também será disponibilizado os notebooks para consulta na página pessoal:

[rafaelescoriza/MVP_PUCRio_EngenhariadeDados_Rafael: Trabalho de pós-graduação do módulo de engenharia de dados](#)

3 Metadados

Com as informações fornecidas pelo próprio site, chegou-se as seguintes descrições dos campos fornecidos integralmente pela base de dados:

Título	Descrição	Range	Tipagem
ID	Identificador único atribuído a cada registro de estudante.	ST000001 a ST50000	String
Idade	Idade do estudante, em anos.	Max: 30 Min: 18	Integer
Genero	Gênero do estudante.	Male or Female	String
Senioridade_facul	Ano acadêmico atual do estudante	Freshman, Sophomore, Junior ou Senior	String
Curso	Principal área de formação do estudante.	-	String
Presenca	Percentual geral de frequência durante o ano acadêmico.	Max: 100 Min: 50	Integer
hrs_estudo_semanal	Número médio de horas que o estudante dedica aos estudos por semana.	Max: 45 Min: 5	Integer
media_acumulada	Média acumulada das notas (CGPA), em uma escala de 0 a 4,0.	Max: 4.00 Min: 2.02	Number (Double)
desempenho_academico	Categoria de desempenho acadêmico derivada do CGPA.	Excellent, Good, Average or Poor	String
habil_programacao	Nível de proficiência em programação, em uma escala de 1 a 10.	Max: 10 Min: 2	Integer
projetos_concluidos	Projetos completos dentro do estudo acadêmico	Max: 15 Min: 0	Integer
certificacoes	Certificados adquiridos dentro do curso	Max: 8 Min: 0	Integer
hackathons	Quantidade de participações de semana de intensivos de resolução de trabalhos	Max: 10 Min: 0	Integer
exp_lideranca	Experiência de liderança de projetos	Yes ou No	String
Currículo_pontuacao	Pontuação da qualidade e informações de currículo	Max: 100 Min: 53	integer
habil_comunicacao	Habilidade de comunicação interpessoal	Max: 10 Min: 3	Integer
trabalho_em_equipe	Habilidade de trabalho em equipe	Max: 10 Min: 2	Integer
resolucao_problemas	Pontuação de problemas resolvidos nas atividades	Max: 10 Min: 1	Integer
proficiencia_ingles	Proficiência em inglês		String
pontuacao_entrevista	Pontuação de entrevista de trabalho	Max: 100 Min: 31	Integer
situacao_emprego	Status de contratação	Placed ou not Placed	String
area_carreira	Área de atuação profissional	-	String
modo_emprego	Local de atuação profissional	Campus, Off-Campus, Referral	String
salario_inicial	Salário inicial em dólares	Max: 110000 Min: 25096	Integer

Vale lembrar, que foi categorizadas apenas as colunas da tabela gold, que será a utilizada para análise, e num caso hipotético, disponibilizada para outras pessoas trabalharem as informações em indicadores.

Para comentar as colunas, foi utilizada a seguinte fórmula SQL:

```
USE CATALOG catalogo_mvp_engenhariadados;
USE SCHEMA schema_mvp_engenhariadados;

COMMENT ON COLUMN catalogo_mvp_engenhariadados.schema_mvp_engenhariadados.tabela_estudantes_gold_v00.ID IS "Identificador único atribuído a cada registro de estudante";
COMMENT ON COLUMN catalogo_mvp_engenhariadados.schema_mvp_engenhariadados.tabela_estudantes_gold_v00.Idade IS "Idade do estudante, em anos.";
COMMENT ON COLUMN catalogo_mvp_engenhariadados.schema_mvp_engenhariadados.tabela_estudantes_gold_v00.Genero IS "Gênero do estudante.";
COMMENT ON COLUMN catalogo_mvp_engenhariadados.schema_mvp_engenhariadados.tabela_estudantes_gold_v00.Senioridade_facul IS "Ano acadêmico atual do estudante (Freshman, Sophomore, Junior ou Senior).";
COMMENT ON COLUMN catalogo_mvp_engenhariadados.schema_mvp_engenhariadados.tabela_estudantes_gold_v00.Curso IS "Principal área de formação do estudante.";
COMMENT ON COLUMN catalogo_mvp_engenhariadados.schema_mvp_engenhariadados.tabela_estudantes_gold_v00.Presenca IS "Percentual geral de frequência durante o ano acadêmico.";
COMMENT ON COLUMN catalogo_mvp_engenhariadados.schema_mvp_engenhariadados.tabela_estudantes_gold_v00.hrs_estudo_semanal IS "Número médio de horas que o estudante dedica aos estudos por semana.";
COMMENT ON COLUMN catalogo_mvp_engenhariadados.schema_mvp_engenhariadados.tabela_estudantes_gold_v00.media_acumulada IS "Média acumulada das notas (CGPA), em uma escala de 0 a 4,0";
COMMENT ON COLUMN catalogo_mvp_engenhariadados.schema_mvp_engenhariadados.tabela_estudantes_gold_v00.desempenho_academico IS "Categoria de desempenho acadêmico derivada do CGPA.";
COMMENT ON COLUMN catalogo_mvp_engenhariadados.schema_mvp_engenhariadados.tabela_estudantes_gold_v00.habil_programacao IS "Nível de proficiência em programação, em uma escala de 1 a 10.";
COMMENT ON COLUMN catalogo_mvp_engenhariadados.schema_mvp_engenhariadados.tabela_estudantes_gold_v00.projetos_concluidos IS "Projetos completos dentro do estudo acadêmico";
COMMENT ON COLUMN catalogo_mvp_engenhariadados.schema_mvp_engenhariadados.tabela_estudantes_gold_v00.certificacoes IS "Certificados adquiridos dentro do curso";
COMMENT ON COLUMN catalogo_mvp_engenhariadados.schema_mvp_engenhariadados.tabela_estudantes_gold_v00.hackathons IS "Quantidade de participações de semana de intensivos de resolução de trabalhos";
COMMENT ON COLUMN catalogo_mvp_engenhariadados.schema_mvp_engenhariadados.tabela_estudantes_gold_v00.exp_lideranca IS "Experiência de liderança de projetos";
COMMENT ON COLUMN catalogo_mvp_engenhariadados.schema_mvp_engenhariadados.tabela_estudantes_gold_v00.habil_comunicacao IS "Habilidade de comunicação interpessoal";
COMMENT ON COLUMN catalogo_mvp_engenhariadados.schema_mvp_engenhariadados.tabela_estudantes_gold_v00.trabalho_em_equipe IS "Habilidade de trabalho em equipe";
COMMENT ON COLUMN catalogo_mvp_engenhariadados.schema_mvp_engenhariadados.tabela_estudantes_gold_v00.resolucao_problemas IS "Pontuação de problemas resolvidos nas atividades";
COMMENT ON COLUMN catalogo_mvp_engenhariadados.schema_mvp_engenhariadados.tabela_estudantes_gold_v00.proficiencia_ingles IS "Proficiência em inglês";
COMMENT ON COLUMN catalogo_mvp_engenhariadados.schema_mvp_engenhariadados.tabela_estudantes_gold_v00.pontuacao_entrevista IS "Pontuação de entrevista de trabalho";
COMMENT ON COLUMN catalogo_mvp_engenhariadados.schema_mvp_engenhariadados.tabela_estudantes_gold_v00.situacao_emploi IS "Status de contratação";
COMMENT ON COLUMN catalogo_mvp_engenhariadados.schema_mvp_engenhariadados.tabela_estudantes_gold_v00.area_carreira IS "Área de atuação profissional";
COMMENT ON COLUMN catalogo_mvp_engenhariadados.schema_mvp_engenhariadados.tabela_estudantes_gold_v00.modos_emploi IS "Local de atuação profissional";
COMMENT ON COLUMN catalogo_mvp_engenhariadados.schema_mvp_engenhariadados.tabela_estudantes_gold_v00.salario_inicial IS "Salário inicial anual em dólares"
```

Figura 1 - Notebook 07_Qualificando_comentarios_TabelaGold

E para obtidos os ranges das categorias numéricas:

```
USE CATALOG catalogo_mvp_engenhariadados;
USE SCHEMA schema_mvp_engenhariadados;

-- Nesse notebook iremos pegar apenas os tipo inteiros ou numéricos
SELECT
max(idade) as Idade_max, min(idade) as Idade_min,
max(presenca) as presenca_max, min(presenca) as presenca_min,
max(hrs_estudo_semanal) as hrs_estudo_semanal_max, min(hrs_estudo_semanal) as hrs_estudo_semanal_min,
max(media_acumulada) as media_acumulada_max, min(media_acumulada) as media_acumulada_min,
max(habil_programacao) as habil_programacao_max, min(habil_programacao) as habil_programacao_min,
max(projetos_concluidos) as projetos_concluidos_max, min(projetos_concluidos) as projetos_concluidos_min,
max(certificacoes) as certificacoes_max, min(certificacoes) as certificacoes_min,
max(hackathons) as hackathons_max, min(hackathons) as hackathons_min,
max(curriculo_pontuacao) as curriculo_pontuacao_max, min(curriculo_pontuacao) as curriculo_pontuacao_min,
max(habil_comunicacao) as habil_comunicacao_max, min(habil_comunicacao) as habil_comunicacao_min,
max(trabalho_em_equipe) as trabalho_em_equipe_max, min(trabalho_em_equipe) as trabalho_em_equipe_min,
max(resolucao_problemas) as resolucao_problema_max, min(resolucao_problemas) as resolucao_problema_min,
max(pontuacao_entrevista) as pontuacao_entrevista_max, min(pontuacao_entrevista) as pontuacao_entrevista_min,
max(salario_inicial) as Salario_inicial_max, min(salario_inicial) as salario_inicial_min
from tabela_estudantes_gold_v00
```

Figura 2 - 07_Qualificando_ranges_TabelaGold

4 Carga (ETL)

Utilizou-se a ferramenta Azure Databricks, em sua versão grátis (databricks.com/learn/free-edition) conectada a conta google, e dentro da ferramenta foi criada um ambiente de repositórios para os notebooks para consulta e base de dados

4.1 Catálogo, Esquema e Volume

Primeramente, dentro do Databricks, deve-se criar o ambiente que suporta essas estruturas para segregação dos dados, notebooks e organização das pipelines.

4.1.1 Catálogo

É o nível mais alto da hierarquia. Agrupa vários esquemas e funciona como o contêiner raiz de um projeto ou domínio de dados.

4.1.2 Esquema

Fica dentro de um catálogo e agrupa objetos relacionados, como tabelas, views, funções e volumes.

4.1.3 Volume

É objeto dentro de um esquema usado para gerenciar arquivos não tabulares (CSV, imagens, JSON etc.) com governança do Unity Catalog. Diferente de uma tabela, não armazena dados estruturados em linhas e colunas, e sim arquivos brutos

4.1.4 Fórmula SQL

```
-- Criando e utilizando o catalogo a ser utilizado
DROP CATALOG IF EXISTS catalogo_mvp_engenhariadedados CASCADE;
CREATE CATALOG catalogo_mvp_engenhariadedados;
USE CATALOG catalogo_mvp_engenhariadedados;

-- Criando e utilizando SCHEMA para armazenar os dados
DROP SCHEMA IF EXISTS SCHEMA_MVP_Engenhariadedados CASCADE;
CREATE SCHEMA SCHEMA_MVP_Engenhariadedados;
USE SCHEMA SCHEMA_MVP_Engenhariadedados;

-- Criando o volume para subir a tabela CSV
DROP VOLUME IF EXISTS VOLUME_MPV_Engenhariadedados;
CREATE VOLUME VOLUME_MPV_Engenhariadedados;
```

Figura 3 - Notebook - 01_Definindo workspace

O script apresentado, resultou na seguinte árvore dentro do databricks:




Figura 4 - Catálogos e esquemas

Importante observar que as tabelas e volumes não são criados, sendo os próximos tópicos do estudo.

4.2 Base de dados

Através do site Kaggle, foi feito o download do arquivo zip que continha o arquivo CSV com a base de dados que foi utilizada para análise de informação. Subimos o arquivo através das opções do menu no canto direito, iremos utilizar conforme sequência abaixo:

4.2.1 Novo

Na página inicial clicar no símbolo ” +” a esquerda-superior escrito “Novo”:




Figura 5 – Clicar em “Novo”

4.2.2 Adicionar ou carregar dados

Irá abrir uma aba auxiliar, das opções, clicar no símbolo de seta para cima escrito “Adicionar ou carregar dados”:




Figura 6 - Clicar em adicionar ou carregar dados

4.2.3 Fazer upload de arquivos para um volume

Com a tela de opções aberta, vamos fazer o carregamento do arquivo para volume:




Figura 7 - Clicar em "Fazer upload de arquivos para volume"

- Selecionar o arquivo baixado no site Kaggle através do navegador aberto ao clicar em “Solte um ou mais arquivos aqui, ou procure”
- E escolher o volume definido anteriormente



Figura 8 - Subindo o arquivo para o Databricks

4.3 Estrutura medalhão

Para atuar com a engenharia sobre os dados, será criada as tabelas no formato medalhão (Tabelas: bronze, prata e ouro)

4.3.1 Tabela bronze

Para a tabela bronze, carregou-se a estrutura do banco de dados para o esquema pré-definido. Como a estrutura SQL de usar o catálogo e esquema pré-definido se repete nos novos notebooks, sendo necessário utiliza-la a cada nova sessão do databricks, e não causando prejuízos ao entendimento, será considerada apenas as formulas após ela. Caso seja necessária a consulta, está nos notebooks anexados na sessão do Git Hub

```
CREATE OR REPLACE TABLE tabela_estudantes_bronze_v00
AS
SELECT *
FROM read_files(
  '/Volumes/catalogo_mvp_engenhariadedados/schema_mvp_engenhariadedados/
  volume_mpv_engenhariadedados/student_career_success_dataset.csv',
  format => 'csv',
  header => true,
  sep => ','
);
```

Figura 9 – Notebook 02_Criando_Tabela_bronze

Para visualizarmos a tabela, utilizou-se script:

```
SELECT *  
FROM tabela_estudantes_bronze_v00
```

Figura 10 - Notebook 03_Exibindo_tabelaBronze

Resultando na seguinte tabela:

Student_ID	Age	Gender	University_Y...	Major	Attendance_Per...	Study_Hours_Per...	CGPA
ST000001	22	Male	Sophomore	Computer Science	86	21	3.28
ST000002	20	Female	Freshman	Computer Science	64	18	2.53
ST000003	23	Male	Senior	> Information Tech...	75	19	2.83
ST000004	23	Female	Senior	> Information Tech...	80	19	2.8
ST000005	23	Female	Senior	Software Engineering	73	19	2.93
ST000006	21	Male	Senior	Computer Science	85	32	3.41
ST000007	21	Male	Junior	Artificial Intelligence	73	18	3

Tabela 1 - Tabela bronze

4.3.1.1 Qualidade dos dados

Antes de começar a escrita e execução dos pipelines de tratamentos de dados das tabelas prata e ouro, é necessário verificar os números totais da tabela, para ter uma visão da qualidade de informações e do quanto iremos utilizar da tabela.

Para isso, utilizar a seguinte fórmula:

```
SELECT COUNT(*) AS Contagem_linhas,  
COUNT(DISTINCT Student_ID) AS Contagem_distintos,  
COUNT_IF (Student_ID IS NULL) AS Contagem_null,  
COUNT_IF (starting_Salary_USD = 0 ) AS Contagem_semsalario,  
COUNT_IF (starting_Salary_USD > 0 ) AS Contagem_comsalario,  
COUNT_IF (Placement_Status = 'Placed') AS Contagem_empregados  
FROM tabela_estudantes_bronze_v00
```

Figura 11 - Notebook 03a_Qualidade_dados

Com isso chegou-se nos seguintes números:

- Total de linhas: 50000
- Contagem de distintos: 50000
- Contagem de nulos: 0

- Contagem de estudantes sem salário: 10960
- Contagem de estudantes com salário: 39040
- Contagem de estudantes empregado: 39040

	Contagem_linhas	Contagem_distintos	Contagem_null	Contagem_sensalario	Contagem_comsalario	Contagem_empregados
1	50000	50000	0	10960	39040	39040

Tabela 2 - Qualidade de dados

Através dos números, foi analisado que essa tabela, por ser sintética (Não representar alunos reais), está uniformizada, não apresentando valores números, com 100% de valores distintos, e todos os alunos que foram empregados com salários, o que iremos utilizar para análise.

Como a base que irá ser utilizada representa 78% da base total, verificou-se que é um número bom para estudarmos o caso, porém sabemos que em evento reais, nem sempre as bases estão com alto nível de qualidade, sendo necessário fazer validações. Após isso, fazer validações de nulo, empregados e salários para reforçar tais números.

Através da validação dos metadados, também foi possível visualizar que as colunas strings estão padronizadas com cursos, respostas e sem valores, além de opções mais restritivas como Gênero ou empregado, que possuem apenas 2 opções, melhorando a qualidade das mesmas, e evitando colunas vazias ou fora do padrão

4.3.2 Tabela prata

Nesta etapa de tratamento de dados, padronizou-se os nomes em português, indicados nos metadados e excluir a última (*Rescued_data*), que não possui valores validos:

```
-- Ajustando os nomes das colunas
CREATE OR REPLACE TABLE tabela_estudantes_silver_v00 AS
SELECT Student_ID as ID, Age as Idade, Gender as Genero, University_Year as Senioridade_Facul, Major as Curso,
Attendance_Percentage as Presenca, Study_Hours_Per_Week as hrs_estudo_semanal, CGPA as media_acumulada,
Academic_Performance as desempenho_academico, Programming_Skill as habil_programacao, Projects_Completed as
projetos_concluidos, Certifications as certificacoes, Hackathons as hackathons, GitHub_Profile as perfil_github,
Internships as estagios, Leadership_Experience as exp_lideranca, LinkedIn_Profile as perfil_linkedin, Resume_Score as
curriculo_pontuacao, Communication_Skills as habil_comunicacao, Teamwork as trabalho_em_equipe, problem_solving as
resolucao_problemas, English_proficiency as proficiencia_ingles, Interview_Score as pontuacao_entrevista,
Employability_Score as pontuacao_emprego, Placement_Status as situacao_emprego, Company_tier as nivel_empresa,
Career_field as area_carreira, Placement_mode as modo_emprego, Starting_Salary_USD as salario_inicial
FROM tabela_estudantes_bronze_v00;
```

Figura 12- Notebook 04_Criando_tabelaSilver

Visualizando:

```
SELECT *
FROM tabela_estudantes_silver_v00
```

Figura 13 - Notebook 05_Exibindo_tabelaSilver

Tabela resultante:

A ^B _C ID	1 ² ₃ Idade	A ^B _C Genero	A ^B _C Senioridade_Facul	A ^B _C Curso	1 ² ₃ Presenca	1 ² ₃ hrs_estudo_semanal
ST000001	22	Male	Sophomore	Computer Science	86	21
ST000002	20	Female	Freshman	Computer Science	64	18
ST000003	23	Male	Senior	> Information Techn...	75	19
ST000004	23	Female	Senior	> Information Techn...	80	19
ST000005	23	Female	Senior	Software Engineering	73	19
ST000006	21	Male	Senior	Computer Science	85	32
ST000007	21	Male	Junior	Artificial Intelligence	73	18
ST000008	23	Male	Freshman	Business Analytics	82	20
ST000009	23	Female	Freshman	Computer Science	82	39

Tabela 3 - Tabela prata

4.3.3 Tabela ouro

Para a última etapa da tabela ouro, que será consumida através de possíveis dashboards e outras análise no próprio banco de dados, será aplicada as regras pré-estabelecidas em objetivo.

Retirarou-se primeiramente os dados comparativos de empresas e desempenho profissional, visto que a análise busca o resultado do salário inicial pelo desempenho acadêmico

Também será excluída das análises, estudantes que não possuem salário, não estão empregados, e possíveis erros de identificação

```
CREATE OR REPLACE TABLE tabela_estudantes_gold_v00 AS
-- Para avaliação do quanto os estudos impactam apenas no salário do profissional, iremos excluir campos
comparativos dos níveis das empresas, pontuações profissionais, e impactos das redes sociais sobre o valor (tema que
exigiria um estudo profundo a parte)
SELECT ID, Idade , Genero , Senioridade_Facul ,Curso,Presenca,hrs_estudo_semanal, media_acumulada,
desempenho_academico, habil_programacao,projetos_concluidos,certificacoes, hackathons, exp_lideranca,
curriculo_pontuacao,habil_comunicacao, trabalho_em_equipe, resolucao_problemas, proficiencia_ingles,
pontuacao_entrevista,situacao_emprego, area_carreira,modo_emprego, salario_inicial
FROM tabela_estudantes_silver_v00
-- Iremos comparar apenas os estudantes que estão empregados com algum salário
WHERE salario_inicial > 0
AND situacao_emprego = "Placed"
-- Removendo valores não nulos
AND ID IS NOT NULL;
```

Figura 14 - Notebook 06_Criando_tabelaGold

Visualizando:

```
select *
from tabela_estudantes_gold_v00
```

Figura 15 - 07_Exibindo_TabelaGold

Tabela resultante:

A _C ID	I ₃ Idade	A _C Genero	A _C Senioridade_Facul	A _C Curso	I ₃ Presenca	I ₃ hrs_estudo
ST000001	22	Male	Sophomore	Computer Science	86	
ST000003	23	Male	Senior	Information Technology	75	
ST000005	23	Female	Senior	Software Engineering	73	
ST000006	21	Male	Senior	Computer Science	85	
ST000007	21	Male	Junior	Artificial Intelligence	73	
ST000009	23	Female	Freshman	Computer Science	82	
ST000011	21	Male	Junior	Data Science	84	
ST000013	22	Female	Freshman	Software Engineering	79	
ST000015	20	Male	Junior	Computer Science	72	

Tabela 4 - Tabela ouro

4.4 Estrutura das tabelas

Devido ao carácter sintético da tabela, não houve a necessidade de cruzamento de informações com outras tabelas e criação de dimensões, o que gerou a não aplicabilidade dos esquemas estrela/floco de neve. Utilizaremos apenas uma grande tabela, ou “Wide table”.

5 Análise de dados

Com a tabela ouro padronizada, será feita as análises dos dados conforme os direcionamentos das perguntas iniciais.

5.1 Horas de estudo

A coluna *hrs_estudo_semanal* nos dias quanto o aluno separa semanalmente do dia extracurricular para estudar, nos direcionando para uma análise de esforço ou dedicação, uma característica que não depende do talento natural de qualquer pessoa.

Para isso, utilizar a seguinte fórmula SQL:

```
SELECT ROUND(hrs_estudo_semanal,0) as hrs_estudo_semanal,
ROUND(AVG(salario_inicial),0) as Salario_Medio
FROM tabela_estudantes_gold_v00
GROUP BY hrs_estudo_semanal
ORDER BY hrs_estudo_semanal DESC
LIMIT 200
```

Figura 16 - Notebook 08_Gold_Questões_00

Exibindo a tabela:

	1.2 hrs_estudo_semanal	1.2 Salario_Medio
1	45	91983
2	44	95353
3	43	93094
4	42	92319
5	41	87045
6	40	92188
7	39	88400
8	38	89985
9	37	89963
10	36	90005
11	35	89525
12	34	89650
13	33	89847
14	32	88946
15	31	88727

Tabela 5 - Horas de estudo semanal

Resultando em um gráfico de dispersão:




Gráfico 1 - Gráfico de dispersão do salário médio pelas horas de estudo semanal

Com as informações, é possível detectar um padrão de melhora no salário médio, conforme aumenta o seu esforço semanal, ficando na faixa ótima entre 40 e 45 horas semanais, com uma dispersão em 41 horas.

5.2 Desempenho acadêmico

O indicador desempenho_academico remete ao desempenho das matérias cursadas de modo discreto, apresentando notas gerais como ruim, médio, bom e excelente. Esse indicador mede notas e qualidade que o aluno absorve, de um modo geral representando a aderência das notas nas matérias cursadas, independente do esforço.

Para isso, utilizar a seguinte fórmula SQL:

```
SELECT desempenho_academico,
ROUND(AVG(salario_inicial),0) as Salario_Medio
FROM tabela_estudantes_gold_v00
GROUP BY desempenho_academico
ORDER BY salario_medio DESC
```

Figura 17 - Notebook 08_Gold_Questões_01

Exibindo a tabela:

	^A _C desempenho_academico	1.2 Salario_Medio
1	Excellent	89795
2	Good	89662
3	Average	87717
4	Poor	79041

Tabela 6 - Desempenho acadêmico

Resultando em um gráfico de colunas:




Gráfico 2 - Gráfico de barras do salário médio pelo desempenho acadêmico

Através da tabela, pode-se identificar que quanto melhor seu desempenho acadêmico nas matérias, melhor será o salário médio.

5.3 Certificações

Dentro do período acadêmico, ou extracurricular, o aluno pode fazer cursos que geram certificações, que aumenta a densidade curricular, e conhecimento. Isso analisa com o mercado visualiza a formação do aluno.

Para isso, utilizar a seguinte fórmula SQL:

```
SELECT certificacoes,  
ROUND(AVG(salario_inicial),0) as Salario_Medio  
FROM tabela_estudantes_gold_v00  
GROUP BY certificacoes  
ORDER BY salario_medio DESC
```

Figura 18 - Notebook 08_Gold_Questões_02

Exibindo a tabela:

1 ² ₃ certificacoes	1.2 Salario_Medio
8	104842
5	89583
4	89157
3	89112
2	88310
1	88250
0	87475
6	86937
7	86778

Tabela 7 - Número de Certificações

Resultando em um gráfico de dispersão:




Gráfico 3 - Gráfico de dispersão do salário médio pelo número de certificações

Não há uma linearidade aparente na relação entre cursos e salário médio, apenas um crescimento vertiginoso naqueles que completaram 8 cursos, parecendo ser o número ideal.

5.4 Habilidade de comunicação e trabalho em equipe

A habilidade de comunicação e trabalho em equipe, é algo característico da pessoa ao chegar no ensino superior. Essa habilidade também pode ser desenvolvida em qualquer idade, por isso iremos analisar com uma característica pessoal.

Para isso, utilizar a seguinte fórmula SQL:

```
SELECT habil_comunicacao, trabalho_em_equipe,  
ROUND(AVG(salario_inicial),0) as Salario_Medio  
FROM tabela_estudantes_gold_v00  
GROUP BY habil_comunicacao, trabalho_em_equipe  
ORDER BY salario_medio DESC
```

Figura 19 - Notebook 08_Gold_Questões_03

Exibindo a tabela:

	1^2_3 habil_comunicacao	1^2_3 trabalho_em_equipe	1.2 Salario_Medio
1	7	2	108586
2	9	2	92576
3	10	3	91769
4	9	10	90236
5	9	4	90026
6	9	9	89855
7	10	8	89810
8	10	10	89791
9	10	6	89790
10	9	5	89759
11	10	9	89759
12	10	7	89609
13	9	6	89545
14	10	5	89495
15	9	8	89473

Tabela 8 - Habilidade comunicação e trabalho em equipe

Resultando nos gráficos de colunas:




Gráfico 4 - Barras do salário médio pela habilidade de comunicação




Gráfico 5 - Barras do salário médio pelo trabalho em equipe

É visto que o trabalho em equipe, não apresenta nenhuma relação, já a comunicação é algo totalmente linear, apresentado um caráter significativo para análise

5.5 Inglês

Será assumido que essa coluna representa uma língua estrangeira aprendida pelo aluno, e seu nível de proficiência médio entre escuta, escrita e fala.

Para isso, utilizar a seguinte fórmula SQL:

```
SELECT proficiencia_ingles ,
ROUND(AVG(salario_inicial),0) as Salario_Medio
FROM tabela_estudantes_gold_v00
GROUP BY proficiencia_ingles
ORDER BY salario_medio DESC
```

Figura 20 - Notebook 08_Gold_Questões_04

Exibindo a tabela:

	^A _C proficiencia_ingles	1.2 Salario_Medio
1	Advanced	89441
2	Intermediate	82676
3	Basic	60654

Tabela 9 - Proficiência de inglês

Resultando em um gráfico de colunas:




Gráfico 6 - Barras do salário médio pela proficiência de inglês

Com a essa análise também é notável a importância do aprendizado prévio, ou cursos de línguas para a vida acadêmica de um estudante

5.6 Características complementares

Verificou-se que um maior nível de horas de estudo, desempenho acadêmico, habilidade comunicação e proficiência em inglês, são importantes para um salário médio maior.

De modo a simplificar a análise, vamos analisar o panorama geral da tabela criada dos cruzamentos dessas informações e considerar só os alunos de que geraram alta performance e salário médio nessas condições, como:

- 40 ou mais horas de estudo
- Desempenho acadêmico = Excelente ou bom
- Proficiência no inglês = Intermediário ou avançado
- Habilidade de comunicação acima 7

Para isso, utilizar a seguinte fórmula SQL:

```

SELECT
  ROUND(hrs_estudo_semanal,0) as hrs_estudo_semanal,
  desempenho_academico,
  habil_comunicacao,
  proficiencia_ingles,
  ROUND(AVG(salario_inicial),0) as Salario_Medio
FROM tabela_estudantes_gold_v00
WHERE hrs_estudo_semanal >= 40
  AND (desempenho_academico = 'Excellent' OR desempenho_academico = 'Good')
  AND (proficiencia_ingles = 'Advanced' OR proficiencia_ingles = 'Intermediate')
  AND habil_comunicacao > 7
GROUP BY hrs_estudo_semanal, certificacoes, desempenho_academico, habil_comunicacao, proficiencia_ingles
ORDER BY salario_medio DESC

```

Figura 21 - Notebook 08_Gold_Questões_05

Exibindo a tabela:

	1.2 hrs_estudo...	A.2 desempenho...	1.2 habil_comunic...	A.2 proficiencia_ingles	1.2 Salario_Medio
1	40	Good	8	Intermediate	109629
2	44	Good	9	Advanced	108086
3	40	Good	9	Advanced	106897
4	41	Excellent	9	Advanced	106627
5	41	Good	9	Advanced	106550
6	44	Good	10	Advanced	106416
7	41	Excellent	9	Advanced	106405
8	42	Good	8	Advanced	105867
9	44	Excellent	9	Advanced	105677
10	42	Excellent	10	Advanced	105630
11	45	Good	10	Advanced	105163

Tabela 10 - Características complementares

Aqui é visualizada que não há um padrão de característica ou direcionamento que melhore combinadamente com salário médio.

6 Conclusão

Através da engenharia de dados, feita com auxílio da plataforma Databricks, as tabelas e gráficos junto aos cruzamentos das informações acadêmicas, visando sempre o máximo salário médio, verificou-se que a melhor característica para um aluno é ter um bom desempenho atrelado as características analisadas na seção 5.6.

Porém, a análise sugere que destaque isolado não é o fator decisivo: entre os alunos selecionados, o maior salário médio não pertenceu a quem teve a melhor pontuação em uma característica específica, e sim a quem manteve um equilíbrio entre esforço, habilidades pessoais e aderência aos estudos.

Tal afirmativa, nos permite visualizar que o aluno que consegue equilibrar o tempo de estudo, aderência a matéria, proficiência em línguas e saiba se comunicar, de modo que não precise ser brilhante, já possui um retorno excelente de salário

7 Autoavaliação

A base de dados avaliada ficou uniforme devido ao fato de ser sintética, isso ajuda nos passos de limpeza, verificação de qualidade dos dados, trabalho para comparar números, já que quase tudo vem padronizado. Porém, a análise perde muito em qualidade por não serem números reais, que possam ajudar os alunos realmente a entenderem o cenário de uma vida acadêmica, mirando num bom salário profissional

Adicionalmente, não foi necessária a junção de tabelas, ou criação de tabelas dimensões para entender melhor os cenários. Uma tabela real, com informações não sensíveis, mas que poderiam possuir informações para junção e enriquecimento da análise, seriam o ideal para continuação dessa análise, como questões regionais e abranger outros tipos de cursos.

Por fim, acredito que foi extraído boas ideias, e análise que ficam de base para utilizar em pesquisar futuras, ou aplicação de informações reais, sem inserir dados sensíveis, e analisar quais desses atributos são realmente importantes, e direcionar para melhora de qualidade de vida acadêmica de um estudante